

Parte A

→ Bloque completo con decoders

Frases: "El banco aguenta"

1) Entrada ($X = E + P$)

→ Embeddings de palabras + posicionales

→ Así, el modelo sabe qué lugar ocupa cada palabra en la frase.

$$X_0(\text{El}) = [0, 0, 0, 1] + [0, 0, 0, 0] = [0, 0, 0, 1]$$

$$X_1(\text{banco}) = [1, 1, 0, 0] + [0, 0, 0, 1] = [1, 1, 0, 1]$$

$$X_2(\text{aguenta}) = [1, 0, 1, 0] + [0, 0, 0, 2] = [1, 0, 1, 2]$$

2) Proyecciones ($Q = XW_q$, $K = XW_k$, $V = XW_v$)

→ Vectores de entrada ^{se mapean} a tres subespacios distintos, para el cálculo de la atención.

→ Q (Queries): aquello que el token busca

K (Keys): " " " " contiene

V (Values): información que se va a propagar

!!! w_q y w_k son identidades $\Rightarrow$

$$\Rightarrow Q = X \text{ y } V = X.$$

$$\begin{matrix} X \\ \uparrow \end{matrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \rightarrow W_k$$

* Acomodo las matrices así por comodidad al ~~calcular~~ multiplicarlas!

$$\begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 0 \end{bmatrix} \rightarrow K$$

3) Afinidad ($S = QK^T$)

→ El producto escalar mide similitud entre Queries y Keys, determinando qué tanta atención debe prestar cada token a los demás

$$\begin{matrix} Q \\ \uparrow \end{matrix} \begin{bmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix} \rightarrow K^T$$

$$\begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{bmatrix} \rightarrow S$$

4) Escala ($S/\sqrt{d}$)

→ Al dividir por la raíz de la dimensión evitamos que los productos crezcan demasiado en los softmax a veces / gradientes en los.

$$S_{escala} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 1,5 \\ 0 & 0,5 & 1 \end{bmatrix}$$

↑

$\sqrt{d}=2$

5) Máscara causal

→ Reemplazamos los valores por encima de la diagonal con -∞ para evitar un token atienda información de posiciones futuras.

$$S_{mask} = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0,5 & 1 \end{bmatrix}$$

6) Matriz de atención ($A = \text{softmax}(S)$)

→ Transformamos las atenciones en una distribución de prob. por fila (sumar 1).

$$F_0(EI) = [1, 0, 0]$$

$$F_1(\text{bueno}) = [0,264, 0,731, 0]$$

$$F_2(\text{agusta}) = [0,186, 0,307, 0,506]$$

7) Mezcla (AV y $(AV)W_0$)

→ Suma ponderada de valores, c/ los pesos de A, así tenemos el contexto relevante para cada token.

→ W_0 es la identidad, así que la proyección de salida se altera nuestro resultado

$$A \uparrow \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \rightarrow V$$

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0,264 & 0,731 & 0 & 0 \\ 0,186 & 0,307 & 0,506 & 1,505 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,307 & 0,307 & 0,506 & 1,505 \end{bmatrix} \rightarrow AVW_0$$

8) Residual ($Z = X + AVW_0$)

→ Esta suma evita el problema del desvanecimiento, ayuda al flujo del gradiente

↓

$$Z = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 1,831 & 0,307 & 1,506 & 3,505 \end{bmatrix}$$

9) Layer Norm (LN(Z))

→ Normalizamos la fila 2 (es la que usaremos para la predicción) de manera independiente, estabilizando y acelerando así el aprendizaje.

$$\mu_2 = 1,783 \quad \sigma_2^2 = 1,305$$



$$\sigma_2 = 1,142$$

$$LN(Z_2) = [0,026, -1,242, -0,026, 1,508]$$

10) Feed-forward (FFN = ReLU(LN(Z₂), W₁), W₂):
→ ~~Entonces~~ Añadimos transf. no-lineales según la percepción! (W₂ es la identidad).

$$LN(Z_2) \cdot W_1 = [0,026 + 1,242, -0,026 - 1,242, 0, 0] \\ [1,318, -1,318, 0, 0]$$

$$ReLU \rightarrow FFN_2 = [1,318, 0, 0, 0]$$

↓
Valores neg.
son 0

$$11) \text{Residual } (H_2 = Z_2 + FFN_2)$$

→ Segunda conexión residual, propósito similar a la primera!

$$H_2 = [3,131, 0,307, 1,506, 3,505]$$

$$12) \text{Layer Norm Final } (LN(H_2))$$

→ Normalización de la salida

$$\mu_2 = 2,112 \quad \sigma = 1,285$$

$$LN(H_2) = [0,793, -1,405, -0,472, 1,084]$$

13) Predicción

→ Multiplicamos las características finales por la matriz de vocabulario W_{out} , así obtenemos un logit por palabras, para luego calcular sus probabilidades.

$$\text{Logits} = \text{LN}(H_2) \cdot W_{out} = \begin{bmatrix} 0,0 & 0,0 & 0,472 & 0,472 \\ 0,0 & -0,472 & -0,472 & 2(0,1405) \\ 0,0 & 0,0 & -0,472 & -0,472, 1,586, -2,810 \end{bmatrix}$$

$$\text{Softmax} \rightarrow P(\text{pero}) = e^{1,586} / (e^{0,2} + 2e^{-0,472} + e^{1,586} + e^{-2,810}) = 0,596$$

→ Predecir "pero" con 59,6%.

→ Calculamos solo la probabilidad de "pero", pues de esta forma el Logit mayor (1,586).

Función 2: "El banco presta"

1) Entrada ($X = E + P$)

$$X = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix}$$

2) Proyecciones

→ De vuelta, calculamos solo $K = X \cdot W_K$

$$X \cdot \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \rightarrow W_K$$

$$\begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \end{bmatrix} \rightarrow K$$

3) Afirmaciónes ($S = QK^T$)

→ Una vez más, $Q = X$



$$Q = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \rightarrow K^T$$

$$\uparrow$$

$$\begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{bmatrix} \rightarrow \text{Idem a} \\ \text{funcion 1}$$

4, 5, 6) $\rightarrow$ Idem a func 1, pero 5 idénticas.

7) Mezcla (AV y $AV(W_0)$)

$\rightarrow$ Al cambiar "agusta" por "pasta", el vector V_2 cambia el resultado de la fila 2

$$AVW_0 = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,307 & 0,813 & 0,506 & 3,505 \end{bmatrix} \rightarrow \text{Cambia!}$$

8) Residual ($Z = X + AVW_0$)

$$Z = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 0,307 & 1,813 & 1,506 & 3,505 \end{bmatrix}$$

9) Layer Norm ($LN(Z)$)

$\rightarrow$ De vuelta, nos enfocamos solo en F_2

$$\mu_2 = 1,783 \quad \sigma_2 = 1,142$$

$$LN(Z_2) = [-1,292, 0,026, -0,243, 1,508]$$

10) Feed-forward ($FFN = ReLU(LN(Z) \cdot W_2)$)

$$LN(Z_2) \cdot W_2 = [-1,292 - 0,026, 1,292 + 0,026, 0,0] \\ [-1,318, 1,318, 0,0]$$

$$ReLU \rightarrow FFN_2 = [0, 1,318, 0,0]$$

11) Residual ($H_2 = Z + FFN$)

$$H_2 = [0,307, 3,131, 1,506, 3,505]$$

12) Layer Norm Final ($LN(H)$)

$$\mu_2 = 2,112 \quad \sigma = 1,285$$

$$LN(H_2) = [-1,405, 0,793, -0,472, 1,084]$$

13) Proyección

$$\text{Logits} = [0, 0, -0,472, -0,472, 2(-1,405), 2(0,793)]$$

$$[0, 0, -0,472, -0,472, -2,810, 1,586]$$

$P(\text{"dinero"}) = \text{ídem al } P(\text{"pero"})$ ^{capit de} _{"dinero"}
en la frase 1

$$P(\text{"dinero"}) = 0,596$$

→ Pudece "dinero" con 59,6%.

Parte B: Sin máscara causal

Frase 1: "El banco aguanta"

$$\text{Partimos de Seculudo} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 5 \\ 0 & 0 & 1 \end{bmatrix}$$

6) ~~Matriz~~ Matriz de atención

→ A1 no haber -8, la primera fila distribuye
atención equitativamente.

$$A = \begin{bmatrix} 0,333 & 0,333 & 0,333 \\ 0,122 & 0,331 & 0,547 \\ 0,186 & 0,307 & 0,506 \end{bmatrix}$$

7) Mezcla (A.V)

→ "El" termina absorbiendo info. de los
tokens posteriores, al faltar la máscara.

$$A.V = \begin{bmatrix} 0,666 & 0,333 & 0,333 & 1,332 \\ 0,278 & 0,331 & 0,547 & 1,547 \\ 0,813 & 0,307 & 0,506 & 1,505 \end{bmatrix}$$

8) Residual ($Z = X + AV$)

$$Z = \begin{bmatrix} 0,666 & 0,333 & 0,333 & 2,332 \\ 1,878 & 0,331 & 0,547 & 2,547 \\ 1,813 & 0,307 & 1,506 & 3,505 \end{bmatrix}$$

a) Layer Norm ($LN(Z)$)

$$F_0 \rightarrow \mu_0 = 0,916 \quad \sigma_0 = 0,824$$

$$F_1 \rightarrow \mu_1 = 1,576 \quad \sigma_1 = 0,734$$

$$F_2 \rightarrow \mu_2 = 1,783 \quad \sigma_2 = 1,142$$

light-it

$$LN(2) = \begin{bmatrix} -0,302 & -0,703 & -0,703 & 1,708 \\ 0,411 & -0,334 & -1,402 & 1,323 \\ 0,026 & -1,292 & -0,243 & 1,508 \end{bmatrix}$$

Fase 2: "El banco presta"

→ Hasta el paso 6 son iguales, en el 7 al multiplicar por $V=X$, cambia.

7) Mezcla (AV)

$$AV = \begin{bmatrix} 0,333 & 0,666 & 0,333 & 1,332 \\ 0,331 & 0,878 & 0,547 & 1,547 \\ 0,307 & 0,813 & 0,506 & 1,505 \end{bmatrix}$$

8) Residual ($Z = X + AV$)

$$Z = \begin{bmatrix} 0,333 & 0,666 & 0,333 & 2,332 \\ 1,331 & 1,878 & 0,547 & 2,547 \\ 0,307 & 1,813 & 1,506 & 3,505 \end{bmatrix}$$

a) Luger Norm ($LN(2)$)

$$F_0 \rightarrow \mu_0 = 0,416 \quad \sigma_0 = 0,829$$

$$F_1 \rightarrow \mu_1 = 1,575 \quad \sigma_1 = 0,733$$

$$F_2 \rightarrow \mu_2 = 1,782 \quad \sigma_2 = 1,142$$

$$LN(2) = \begin{bmatrix} -0,703 & -0,302 & -0,703 & 1,709 \\ -0,333 & 0,413 & -1,402 & 1,326 \\ -1,291 & 0,027 & -0,241 & 1,508 \end{bmatrix}$$

Preguntas

1) Aunque no lo calculamos (me pasa por no leer las preguntas de intervalo) en la parte A, debería cambiar entre las 2 fases solo en la parte B, pero solo ahí, ya falta de máscara causal, se mezcla el contexto posterior ("presta" vs. "apunta") con el de "banco".

2) Con el contexto que se fue
"acumulando" hacia la última posición
de la secuencia

3) Son iguales, la máscara no influye
en la última posición al no haber
palabras futuras que ocultar.

4) Parte A: GPT, para generación
Parte B: BERT, para clasificación o
extracción

5) Se añaden la direccionalidad, resultando
en un ~~bag~~ "bag of words". El módulo
no podría resolver frases donde el
orden altera el sentido.